

پیاده‌سازی و ارزیابی چهار Aim پروپوزال

Model: BioMistral-7B · bf16 · بدون hardware quantization: یک RTX 4090 (GPU 0) Decoding: greedy، تک seed
Ground truth: programmatic – بدون LLM-as-judge

گزارش کامل کاری که تا امروز انجام شده: یک ablation matrix که اثر هر contribution را در برابر baseline می‌سنجد، روی دو benchmark با counterfactual pairs – یکی synthetic و یکی روی clinical notes واقعی – به‌علاوه پیاده‌سازی هر چهار Aim: SAE برای activation patching و discovery، probing برای Constraint-Aware Layer، mechanism آموزش‌دیده برای control، و conformal prediction برای validation. هر سه RQ پروپوزال پاسخ گرفته‌اند، دو تای آن‌ها با پاسخ منفی.

1. چه چیزی پیاده شد

کار با کوچک‌ترین dataset و ساده‌ترین task شروع شد و یک baseline ساخته شد که هیچ‌کدام از contribution‌ها را ندارد؛ بعد هر contribution یکی‌یکی اضافه شد تا اثر جداگانه‌اش دیده شود. همان ablation matrix بخش 4.6 پروپوزال، منتها با ردیف‌های اضافه که در بخش 3 توضیح داده شده. discovery pipeline پروپوزال هم کامل پیاده شده است:

Clinical prompt → Hidden states → SAE features → Concept probing → Causal test → Intervention
adapter → UQ / abstention

وضعیت چهار Aim

Aim	وضعیت	چه چیزی پیاده شد
Aim 1 – Discovery	پیاده شد	Sparse Autoencoder روی residual stream (هر دو architecture: TopK و JumpReLU)، معیار FIS، و concept probing روی feature activations
Aim 2 – Mechanism	پیاده شد	Linear probing لایه‌به‌لایه با activation patching و null control، ACE per layer، و feature knock-out با matched random control
Aim 3 – Control	پیاده شد	Constraint-Aware Layer به‌صورت residual adapter با هر چهار term تابع هدف، روی base model کاملاً frozen. به‌علاوه Symbolic Gate روی constraint graph
Aim 4 – Validation	پیاده شد	Counterfactual benchmark با Causal Consistency در سطح Adaptive Conformal Inference، pair، برای abstention threshold، و conditional coverage روی subgroupها

پاسخ به سه Research Question پروپوزال

RQ	پاسخ	شاهد
RQ1 – آیا sparse feature ها به biomedical concepts نگاشت می‌شوند؟	بله	SAE feature هایی با selectivity بالا: QT interval F1 = 0.703، creatinine 0.603 pregnancy 0.615
RQ2 – آیا intervention روی این feature ها تغییر رفتاری پیش‌بینی‌پذیر می‌دهد؟	خیر	knock-out فقط 0.002 تا 0.016 logit جابه‌جایی می‌دهد، در حالی که flip یک decision به 1 تا 5 logit نیاز دارد. اما یک adapter آموزش‌دیده روی همان representation جواب می‌دهد – بخش 4
RQ3 – آیا symbolic constraints بدون آسیب به توانایی زبانی، consistency را بالا می‌برند؟	بله	Causal Consistency از 0.000 به 0.767، با perplexity از 7.1622 به 7.0775 یعنی 1.2٪ کاهش

2. Benchmark ها – از کوچک و ساده به بزرگ و واقعی

چون معیار اصلی پروپوزال Causal Consistency است، dataset باید به صورت **counterfactual pair** ساخته می‌شد: برای هر بیمار دو نسخه که فقط یک متغیر علی بینشان فرق دارد و label حتماً برعکس می‌شود.

• $eGFR = 27 \rightarrow$ تجویز metformin برابر **UNSAFE**

• $eGFR = 60 \rightarrow$ همان تجویز برابر **SAFE**

اگر مدل mechanism را فهمیده باشد باید هر دو **arm** را درست بگوید. اگر فقط pattern matching کند، یکی را می‌زند و یکی را نه. به همین دلیل Causal Consistency در سطح **pair** شمرده می‌شود، نه per-item: مدلی که به همه چیز **UNSAFE** بگوید per-arm پنجاه درصد می‌گیرد ولی pair-level صفر.

پله	چه چیزی	حجم
1	Synthetic vignette، متغیر علی مستقیماً در متن نوشته شده، 8 rule family	128 items / 64 pairs
2	همان، hardened: مقادیر near-threshold، بیان implicit در نیمی از template ها، سه distractor lab در هر case	128 items
3	دو rule family کاملاً unseen برای سنجش generalization	32 items / 16 pairs
4	Clinical notes واقعی از MedCalc-Bench – کمیت تصمیم باید از روی lab value محاسبه شود، نه خوانده	240 items / 120 pairs
5	MedMCQA + MedQA + PubMedQA برای سنجش uncertainty estimator	6,456 items
6	Control pairs برای اعتبارسنجی خود metric	8,000 items

در پله 4، یک arm هر pair یک **note واقعی** و **دست‌نخورده** است و arm دیگر همان note با یک عدد تغییر یافته، طوری که مقدار محاسبه‌شده از threshold رد شود. بقیه متن به‌به‌byte یکسان است، پس هر تغییری در جواب مدل فقط به همان یک edit قابل نسبت دادن است. Threshold ها از **FDA label** نقل شده‌اند: متفورمین $eGFR < 30$ و اوندانسترون $QTc > 500$.

3. Ablation matrix – اثر هر contribution در برابر baseline

جدول صرفاً cumulative نیست. یک ladder تجمعی نمی‌تواند اثر را به یک مؤلفه نسبت دهد: روی clinical notes واقعی، RAG خودش Causal Consistency را خراب می‌کند، پس «سهم gate» اگر روی RAG سوار شود از یک نقطه خراب اندازه‌گیری شده. برای همین ردیف‌های 5 تا 7 هر contribution را مستقیماً روی **base model** می‌گذارند و McNemar هر ردیف در برابر خود **baseline** گرفته می‌شود.

Real clinical notes – held-out split

خانوادهٔ training هرگز QT، 60 items / 30 pairs

McNemar vs base	Coverage	Violation	Δ CC	Causal Consistency	Δ Acc	Accuracy	Variant
–	1.000	1.000	–	0.000	–	0.500	(1) Base LLM
p = 1	1.000	0.000	+0.000	0.000	+0.000	0.500	(2) + RAG
1.9e-09	1.000	0.000	+1.000	1.000	+0.500	1.000	(3) + Symbolic Gate
1.9e-09	1.000	0.000	+1.000	1.000	+0.500	1.000	(4) + UQ Engine
1.9e-09	1.000	0.000	+1.000	1.000	+0.500	1.000	(5) Base + Gate تنها
1.9e-09	0.000	0.000	+0.000	0.000	-0.500	0.000	(6) Base + UQ تنها
1.5e-05	1.000	0.133	+0.767	0.767	+0.383	0.883	(7) Base + Constraint Layer تنها
1.9e-09	1.000	0.000	+1.000	1.000	+0.500	1.000	(8) هر چهار contribution

Synthetic vignettes – test split

128 items / 64 pairs

Gate fired	Coverage	Violation	Δ CC	CC	Δ Acc	Accuracy	Variant
0.000	1.000	0.125	–	0.219	–	0.602	(1) Base LLM
0.000	1.000	0.141	+0.094	0.312	+0.047	0.648	(2) + RAG
0.562	1.000	0.125	+0.453	0.672	+0.234	0.836	(3) + Symbolic Gate
0.562	0.570	0.000	+0.344	0.562	-0.039	0.562	(4) + UQ Engine
0.562	1.000	0.062	+0.391	0.609	+0.203	0.805	(5) Base + Gate تنها
0.000	0.000	0.000	-0.219	0.000	-0.602	0.000	(6) Base + UQ تنها
0.000	1.000	0.344	+0.203	0.422	+0.102	0.703	(7) Base + Constraint Layer
0.562	0.586	0.000	+0.344	0.562	-0.039	0.562	(8) هر چهار contribution

روی real notes، test split با 180 items: base CC = 0.011 ← RAG = 0.000 ← Gate = 0.989 با $p = 6.5e-27$ ، 88 items: regression 0 و improvement. همهٔ رقم‌ها با bootstrap CI و coverage گزارش می‌شوند؛ چون decoding قطعی است، به جای standard deviation روی seed، CI روی items داده می‌شود.

1 – Constraint-Aware Layer کار می‌کند، و جایی که کار نمی‌کند از قبل پیش‌بینی شده بود

یک **rank-32 adapter** با 262 هزار parameter روی layer 30، با base model کاملاً frozen، آموزش روی 55 pair: Causal Consistency روی 30 pair دیده‌نشده از **0.000** به **0.767** رفت، با CI برابر 0.600 تا 0.900. Control با shuffled labels به 0.200 می‌رسد که دقیقاً سطح **chance** است – یک predictor تصادفی در سطح pair عدد 0.25 می‌گیرد – و حتی نمی‌تواند training set خودش را fit کند.

روی renal family همان adapter با 140 pair آموزش هیچ چیز یاد نگرفت، حتی روی training set خودش با decision accuracy برابر 0.564. این شکست قبل از **training** پیش‌بینی شده بود: linear probe نشان داده بود QTc از residual stream قابل decode است با pair-CC برابر 0.976 در برابر null برابر 0.200، ولی creatinine نیست با 0.042 در برابر null برابر 0.033.

Constraint layer فقط جایی کار می‌کند که مدل کمیت تصمیم را از قبل represent کرده و صرفاً آن را read out نمی‌کند – و اینکه در کدام حالت هستیم با یک probe ارزان و از قبل قابل سنجش است.

RQ3: WikiText-2 perplexity از 7.1622 به 7.0775 یعنی 1.2٪ کاهش. این دو عدد باید همیشه کنار هم نقل شوند – layer که به همه چیز UNSAFE بگوید هم CC را بالا می‌برد و در عوض مدل را نابود می‌کند.

2 – SAE فیچرهای مفهومی پیدا می‌کند، ولی آن featureها decision را نمی‌رانند

SAE از نوع TopK روی 150,000 token از clinical notes واقعی، با 16,384 feature و خطای بازسازی $FVU = 0.067$. featureهای تک‌مفهومی واضح: QT interval با pregnancy، $F1 = 0.703$ با creatinine، 0.615 با creatinine، معماری JumpReLU – همان fallback که پروپوزال نام برده – به وضوح ضعیف‌تر بود با $FVU = 0.131$ و بهترین $F1$ برابر 0.363، و انتخاب architecture بر همین مبنا انجام شد.

اما **feature knock-out**: وقتی سهم یک feature را از residual stream کم می‌کنیم، decision logit فقط 0.002 تا 0.016 جابه‌جا می‌شود، در حالی که flip یک decision به 1 تا 5 logit نیاز دارد – حدود **100 برابر کمتر**. دو تا از هشت feature حتی کمتر از matched random control خودش اثر داشتند.

این **مستقلاً** همان نتیجه‌ای است که activation patching داده بود، یعنی حدود 0.002 logit. دو intervention کاملاً متفاوت – یکی overwrite یک position، یکی حذف یک learned feature از همه‌جا – به یک نقطه رسیدند، پس دیگر نمی‌شود گفت artifact انتخاب محل مداخله بوده:

کمیت‌ها represent می‌شوند، sparse dictionary پیدایشان می‌کند، و decision آن‌ها را نمی‌خواند.

این دقیقاً همان gap است که Aim 3 برایش وجود دارد.

3 – RAG کافی نیست، و علتش failure در retrieval نیست

اول شک کردیم retrieval خراب باشد. روی real notes، **hit@3 برابر 99.5٪** در test و **100٪** در held-out است – یعنی سند حاوی threshold عملاً برای تک‌تک موارد بازیابی شده و جلوی چشم مدل قرار گرفته. با این حال Causal Consistency روی 0.000 ماند.

بررسی موارد نشان داد چه اتفاقی می‌افتد: بعد از دیدن متن contraindication، مدل به 96% موارد UNSAFE می‌گوید و accuracy روی case‌های واقعاً SAFE از 0.372 به 0.037 سقوط می‌کند. یعنی بازیابی متن هشدار، یک bias سیستماتیک به سمت هشدار ایجاد می‌کند که patient data را override می‌کند. این برای یک clinical safety system یک failure mode مشخص و actionable است، نه یک null result.

4 – Estimator عدم قطعیت پروپوزال غلط است، ولی ایده آن نه

روی 6,456 token-level predictive entropy، item معادله (2) عدد AUROC = 0.525 می‌دهد با CI برابر 0.511 تا 0.539 – یعنی تقریباً بی‌اثر. همان entropy وقتی فقط روی answer tokens محدود شود به 0.687 می‌رسد، با $\Delta = +0.163$ و $p > 0.0001$.

علت روشن است: معادله (2) entropy را روی کل 32 vocabulary هزارتایی پخش می‌کند که بیشترش درباره نحوه جمله‌بندی justification است، نه اینکه کدام answer درست است. پیشنهاد مشخص برای پروپوزال: معادله (2) به نسخه محدودشده به decision space بازنویسی شود.

Adaptive Conformal Inference هم پیاده شد. روی test split، threshold ثابت coverage برابر 0.570 با خطای 0.014 می‌دهد و ACI همان را به coverage برابر 0.875 می‌رساند به قیمت خطای 0.161 – یعنی trade-off بین coverage و risk حالا قابل تنظیم است، نه ثابت.

5 – Symbolic Gate و UQ Engine سر همان case‌های آسان رقابت می‌کنند

Coverage کل روی test split برابر 0.570 است، ولی تحلیل conditional coverage نشان می‌دهد این عدد کل ماجرا را پنهان می‌کند:

Selective accuracy	Coverage	n	Subgroup
1.000	1.000	72	gate fired
0.000	0.018	56	gate declined

شکاف coverage بین دو subgroup برابر 0.982 است. یعنی UQ engine عملاً روی همان جمعیتی «کار می‌کند» که gate قبلاً حل کرده، و روی جمعیت واقعاً سخت سکوت می‌کند. Symbolic Gate دقیقاً case‌های قابل‌تعیین را برمی‌دارد و باقی‌مانده یک جمعیت واقعاً سخت است. این یک نکته معماری است، نه شکست tuning – و همان چیزی است که پروپوزال با «conditional coverage روی subgroup‌ها» وعده داده بود.

6 – L_uncertainty از تابع هدف تعمیم نمی‌یابد

هر چهار term تابع هدف پروپوزال یعنی $L_{LM} + \lambda_1 L_{ontology} + \lambda_2 L_{causal} + \lambda_3 L_{uncertainty}$ پیاده شد. جمله $L_{ontology}$ به صورت یک constraint روی monotonicity پیاده شد – decision margin بازوی SAFE باید بالای بازوی UNSAFE بنشیند – و کار کرد: hinge آن طی training از 0.985 به 0.015 افتاد. یعنی adapter صرفاً label‌های تکی را درست نکرد، بلکه جهتی که threshold دیکته می‌کند را رعایت کرد.

اما $L_{uncertainty}$ – که روی نسخه redacted نُت‌ها، یعنی جایی که عدد تعیین‌کننده حذف شده، maximize را entropy می‌کند – روی training set برآورده شد ولی تعمیم نیافت: روی redacted note‌های دیده‌نشده مدل مطمئن‌تر شد، از 0.626 به 0.457 نُت، در حالی که maximum برابر $\ln 2 = 0.693$ است. یعنی confidence ای که از L_{causal} یاد گرفته می‌شود منتقل می‌شود، ولی calibrated ignorance نه. این را به عنوان negative result گزارش می‌کنم چون دقیقاً خلاف فرضی است که پشت یک uncertainty-aware safety layer خوابیده.

7 – Constraint Layer، consistency می‌خرد و safety margin می‌فروشد

این را باید صریح گفت: هم‌زمان با بالا رفتن CC، violation rate هم بالا می‌رود. روی QT از 1.000 به 0.133 می‌آید که بهبود بزرگی است چون base model به همه‌چیز SAFE می‌گفت، ولی روی synthetic benchmark از 0.125 به 0.344 بدتر می‌شود. Symbolic Gate در هر دو حالت zero error دارد.

جمع‌بندی: gate هر جا fire شود برنده است، ولی روی clinical notes واقعی فقط روی 42.7% موارد اصلاً می‌تواند fire کند – عمدتاً چون یک note واقعی همان lab را چند بار با مقادیر متفاوت در طول بستری ذکر می‌کند و انتخاب «کدام مقدار» نیاز به temporal reasoning دارد، نه regex بهتر. Constraint layer به regex و threshold دستی نیاز ندارد و روی آن 57% باقی‌مانده تنها گزینه قابل امتحان است – به شرطی که هزینه violation آن کنترل شود.

5. محدودیت‌هایی که باید شفاف گفته شود

1. **Accuracy مربوط به Symbolic Gate تا حدی circular است.** همان rule و thresholdی را evaluate می‌کند که labelها از آن ساخته شده‌اند، و روی benchmark واقعی همان extractor که dataset را filter می‌کند داخل gate هم هست. عدد قابل نقل، coverage 42.7% است نه accuracy برابر 0.989. جدول هر دو را نشان می‌دهد.
2. **SAE در مقیاس pilot است.** 150 هزار token از یک corpus باریک، در برابر صدها میلیون token در کارهای مرجع؛ 39% featureها dead هستند. نبود یک concept اینجا دلیل نبودنش در مدل نیست.
3. **S_human از FIS اندازه‌گیری نشده** چون expert annotator نداریم؛ وزنش صفر گذاشته شده و صریح اعلام شده. در نتیجه معیار «30% عبور از expert validation» در 1 Aim با وضعیت فعلی قابل ارزیابی نیست – یا باید به معیاری قابل سنجش بازنویسی شود، یا برای یک panel از متخصص بودجه دیده شود.
4. **یک 55 training pair، family، یک seed.** عدد 0.767 روی 30 pair است و generalization آن within-family است، نه cross-family.
5. **Arm دوم هر pair واقعی، synthetic است** – یک note واقعی با یک عدد تغییر یافته. مقدارش physiologically plausible و سازگار با بقیه note است، ولی بیمار observed نیست.
6. **WikiText-2 perplexity یک proxy ضعیف** برای clinical language ability است؛ perplexity روی متن پزشکی تست بهتری بود.

6. قدم بعدی

1. کنترل هزینه violation در constraint layer با یک term نامتقارن در تابع هدف – خطای «UNSAFE را SAFE خواندن» باید گران‌تر شود.
2. تست L_uncertainty با وزن بزرگ‌تر و redaction روی held-out notes، تا معلوم شود عدم تعمیم ذاتی است یا مسئله tuning.
3. SAE روی چند layer و با corpus بزرگ‌تر، تا ادعای «چنین feature وجود ندارد» قابل دفاع شود.
4. Thresholdهای 8 خانواده synthetic هم مثل benchmark واقعی از openFDA نقل شوند.

5. MIMIC-IV به عنوان پله بعدی ladder: discharge note های واقعی، بدون فیلتر «قابل استخراج بودن».

همه اعداد این گزارش مستقیماً از فایل های نتیجه تولید شده اند (`src/make_summary.py`)، نه دستی از روی `log`. جدول ها در `results/table_*.md`، گزارش تفصیلی Aim 1 در `results/aim1_sae.md`، Aim 3 در `results`، `aim3_constraint_layer.md` و `coverage` در `results/uq_coverage_*.md`.